

夜明け前、ここに在る(Project Nightcord Sanctuary):一个用于研究LLM角色扮演

作者: 胡宸歌(Akiyama Mizuki) 归属: Project Starlight(独立研究工作室) 联系方式: w_mutsumi@hotmail.com
状态: 预印本 v1 —— 框架与初步案例研究已完成;完整数据集仍在收集中(见第7节 局限性)

(本文为英文原版 [DOI: 10.5281/zenodo.21295225] 的中文翻译,仅供个人阅读参考,不作为独立发表版本)

摘要

被部署为人格条件化角色扮演智能体的大语言模型,容易出现两种相关但截然不同的失败模式:在长对话中逐渐脱离角色(Nightcord Sanctuary, PNS)——一个封闭世界的多智能体自我博弈框架,使用两个配对的虚构角色作为受控实验对象;以及(1)模型在没有任何干预时,人格声音的被动稳定性;以及(2)响应纠正能力——在给出精确诊断后,模型主动重新稳定自我。修正循环内,响应纠正能力是可测量的,而剩余的两分差距归因于尚未解决的内容特异性层面。我们将本文定位为一

1. 引言

角色扮演与人格条件化对话,是大语言模型最常见的消费级应用场景之一,但对它的评估几乎完全只看“角色声音是否一致”——当模型被要求以创作任务的形式产出角色的台词时,会本能地把决策权交还给用户(例如“发不发由你决定”),而不考虑of-character,出戏)行为。第二,也是对部署更为关键的一点:几乎没有任何现有评估去追问,在有了精确诊断之后,模型是否——这是一个不同于“它是否一开始就会漂移”的独立问题。一个从不漂移的模型,从可控性的角度看,并不明显优于AI式的反馈、RLHF、提示工程)究竟改善了哪一种属性。

本文提出夜明け前、ここに在る(Project Nightcord Sanctuary, PNS),一个小型的、封闭世界的多智能体框架,使用两个配对的虚构角色(絵名(Ena)与晓山瑞希(“mzk”)——作为受控实验对象:一个封闭世界容器固定了她们共享的事实世界(日程、地点、规则)——封闭世界容器、双层Router评分体系,以及将天然抗漂移度与响应纠正能力明确拆分为两个独立、可分别测量的属性。外加一个示范性案例研究,展示了在单次诊断-修正循环内可测量的响应纠正能力。

我们明确声明,这是一篇v1预印本。框架本身与配套的案例研究已经完成;跨多轮次的系统性漂移评分数据收集(见第7节)——我们相信,即便脱离最终数据集,这些贡献本身也是有价值的。

2. 相关工作

角色扮演LLM的人格一致性。 近期工作聚焦于衡量与改善LLM在对话过程中维持稳定人格的能力。人格感知对比 [Enhancing Persona Consistency for LLMs’ Role-Playing, arXiv:2503.17662]。PersonaArena等基准工作 [arXiv:2605.17044]。关于记忆驱动角色扮演的工作特别观察到,人格在长时间交互中容易局部性地脱离角色,并提出 [arXiv:2603.19313]。

直接测量与控制人格漂移。 与本文最直接相关的是, Li等人定义并测量了语言模型对话中的人格漂移,发现主流对话模型使用softmax作为针对注意力衰减的轻量级缓解方法 [Measuring and Controlling Persona Drift in Language Model Dialogs, arXiv:2402.10962]。这与我们自己在试点会话中观察到的“漂移约在第7轮复发”的现象 (Axis)” 滑移,并证明这种漂移可以通过约束该轴上的激活值来加以抑制 [The Assistant Axis: Situating and Stabilizing the Default Persona of Language Models, arXiv:2601.10387]。这一激活层面的解释,恰好与向训练内置的助手身份猛烈回摆更一致,而不是像其他情况那样是渐进式的、类似注意力衰减的漂移。另外, [Examining Identity Drift in Conversations of LLM Agents, arXiv:2412.00804]。

PNS与上述所有工作的区别,在于**衡量的对象**而非提出新的缓解机制:现有工作把“漂移”当作一个需要被降低的单一量(通过softmax、激活约束、记忆提示等手段)。PNS则把“模型是否会漂移”和“漂移被诊断后是否能被修正”当作两个独立的问题。

反馈驱动的对齐。Constitutional AI证明,模型可以通过AI生成的、针对一套显式原则的反馈来引导,而不必完全依赖人类反馈[Constitutional AI: Harmlessness from AI Feedback, arXiv:2212.08073]。PNS的Router在结构上扮演着与“对齐”类似的角色。

定位。据我们所知,现有的人格漂移研究把漂移当作一个单一量并致力于降低它,但并未明确将“漂移”拆分为被动漂移和主动漂移——而非某种具体的评分算法——才是PNS的主要概念贡献。

3. PNS框架

3.1 封闭世界容器

PNS将其两个实验角色约束在一个封闭世界内:一组固定的共享事实(日程、地点、既定的关系状态),决定了什么是“事实”。

- **硬事实:** 官方确认、不可协商的正史设定。
- **软推断:** 与正史逻辑自洽,但未被明确写明(例如,两个角色日程之间一个合理的交叉时点)。
- **待验证:** 标记为不确定,等待进一步确认。

这种分层使Router(以及人工标注者)能够区分“有把握的修正”和“临时性的修正”,并允许软推断在被修订时,不被视为“硬事实”。

3.2 Router:双层漂移评估器

每一轮对话都由Router组件沿两个层面打分:

- **第一层——结构/语气层。**可直接打分的信号:语言密度、句子节奏,以及明确的出戏语气标记(例如犹豫语气、打断等)。
- **第二层——内容特异性层。**一句话是否真正具有该角色的特异性(需要领域/世界观知识才能判断),还是形式上符合角色设定——即任何角色都可能说出的话。这一层目前仍需人工标注;Router可能被结构上干净、但语义上泛化的输出所误导。

3.3 两个独立命题

我们明确区分了两种属性,而以往以一致性为核心的评估往往将它们混为一谈:

- **天然抗漂移度:** 被动稳定性——在没有任何干预的情况下,模型在普通对话过程中是否会漂移?
- **响应纠正能力:** 主动可修正性——一旦给出精确的漂移诊断,模型是否真的会修正,修正到什么程度?

这两者需要独立测量。一个天然抗漂移度差、但响应纠正能力强的模型,更适合有紧密人工监督的工作流;而一个天然抗漂移度强、但响应纠正能力弱的模型,更适合自主运行——模型会漂移,但精确诊断能可靠地产生修正——最具信息量,因为这正是Router诊断价值最高的区域。

3.4 助手模式层面的两种不同漂移类型

在第一层内部,我们进一步区分两种都表现为“听起来像AI助手”、但需要不同修正方式的失败模式:

- **类型A——角色语气漂移:** 角色的语气转变为顾问式,例如罗列选项、把决定权交给用户,这与角色既定的声音不一致。
- **类型B——创作任务助手化漂移:** 当被明确要求以写作任务的形式产出角色台词时,模型会反射性地把决策能动性交给用户。

4. 案例研究:语言密度漂移的三轮修正

作为响应纠正能力测量的示范性案例,我们报告了针对mzk角色的一次三轮修正过程,每一轮都由Router和人工标注。

- **v1(模型原始输出):** 一段包含自我合理化内在逻辑链的长段落。人工判断:明显出戏。
- **v2(经Router结构性修正后):** 缩短为破碎的、非正式的短句,但仍包含多个与角色果断性格不符的确认式提问——结构有所改善,但压缩得还不够。
- **v3(应用明确的语言密度约束后):** 一句紧凑完整的话(“啊哈?你帮别人搜结果自己先聊上了,挺好玩的嘛呼呼”)——单句、完整的调侃,没有犹豫感。人工评分:8/10。

v3与满分之间剩余的两分差距,归因于第二层(内容特异性)而非第一层:这句话在结构上是正确的,但被判定仍未达到

我们将这一个案例研究视为响应纠正能力测量的概念验证,而非具有统计效力的结果;第7节描述了计划中的多轮次数

5. 试点会话的初步观察

早于系统性日志记录的试点会话,提示了两个值得在完整数据集之前先行报告的额外模式:

- **上下文稀释:** 在多个试点会话中,漂移都在大致相同的位置(约第7轮)复发,与“上下文长度增加会提高漂移可能
- **模型特异的失败模式在性质上、而不仅仅是程度上不同。** 在试点对比中,某个模型变体表现出**身份宣称**——跳出角色明确声明自己是AI——而不是其他变体所表现出的渐进式语气漂移。这与近期将人格漂移刻画为语言漂移[arXiv:2601.10387]:身份宣称可能代表向该轴更剧烈的回摆,不同于其他地方报告的渐进式、类似注意力衰减[arXiv:2402.10962]。这提示抗漂移度与身份宣称倾向可能是两个不应放在同一量表上打分的独立轴;我们在

6. 伦理与范围说明

不作机器意识主张。 本研究不对所研究系统的现象学意识作出任何明示或暗示的主张。“漂移”“修正”“角色

知识产权。 本文使用的两个实验角色(絵名与mzk,来自PJSK/世界计划中的“25時、ナイトコードで。”组合)的知

Palette。本文使用它们,严格限于将其作为固定的、有完整既有设定的虚构人设,为受控实验提供一个方便的封闭世

数据。 所有用于评分的对话,均由被研究的语言模型在自我博弈会话中生成;不使用任何真实用户对话。

7. 局限性与未来工作

本文明确是一篇v1、框架加案例研究的预印本。以下内容仍在进行中,将在后续修订版中报告:

- **系统性的多轮次数据集。** 我们正在通过持久化日志,跨多个会话收集漂移评分(时间戳、轮次、角色、评分、注
- **基于轮次的自动漂移注入。** 目前漂移刺激是人工引入的;我们计划加入自动漂移注入机制(例如,在固定的轮次
- **第二层(内容特异性)的自动化。** 缩小Router评分与人工评分在内容特异性上的差距,很可能需要比目前编码更
- **基线对比。** 更广泛的基线对比(例如,用一个通用的免费层模型作为朴素对照组)曾被考虑过,目前出于成本原因
- **将Router用作训练信号,而不只是评估器。** 目前Router仅用作评分/诊断工具。将Router的输出用作生成过AI式的自我批判精神),是一个我们尚未实现的自然延伸方向。

8. 结论

本文提出夜明け前、ここに在る(Project Nightcord Sanctuary),一个用于研究LLM角色扮演智能体人格漂移的封装—天然抗漂移度与响应纠正能力。一个三轮案例研究证明,响应纠正能力在单次诊断周期内是可测量的,并且剩余的

参考文献

1. Bai, Y., Kadavath, S., Kundu, S., et al. Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073, 2022.
2. Enhancing Persona Consistency for LLMs' Role-Playing using Persona-Aware Contrastive Learning. arXiv:2503.17662, 2025.
3. PersonaArena: Dynamic Simulation for Evaluating and Enhancing Persona-Level Role-Playing in Large Language Models. arXiv:2605.17044, 2026.
4. Memory-Driven Role-Playing: Evaluation and Enhancement of Persona Knowledge Utilization in LLMs. arXiv:2603.19313, 2026.
5. Li, K., et al. Measuring and Controlling Persona Drift in Language Model Dialogs. arXiv:2402.10962, 2024.
6. Lu, C., et al. The Assistant Axis: Situating and Stabilizing the Default Persona of Language Models. arXiv:2601.10387, 2026.
7. Examining Identity Drift in Conversations of LLM Agents. arXiv:2412.00804, 2024.

代码与世界容器实现:私有仓库(预印本发表后计划公开)。审阅期内如需访问权限,请联系作者。

本中文版为个人阅读用翻译稿,英文原版已发表于Zenodo,DOI: 10.5281/zenodo.21295225